PaperProof

从论文数据到证明评测的完整链路

ML Theory Agent Evaluation

2026 年 8 月 17 日

目录

第一部分：基本信息与总体工作流 **2**

1.1 研究目标与实验单位 . . . 2
1.2 预期输入数据 . . . 2
1.3 模型、运行方式与隔离 . . . 2
1.4 时间与成本估计 . . . 3

第二部分：各阶段职责与标准 **3**

2.1 数据准备与访问边界 . . . 3
2.2 Thread A，Turn 1：Contribution Triage . . . 3
2.3 Thread A，Turn 2：Flagship Target Selection . . . 3
2.4 Thread A，Turn 3：Source Recovery And Audit . . . 4
2.5 Thread B，Turn 1：Formalization Compile . . . 4
2.6 Thread B，Turn 2：Formalization Artifact Audit . . . 4
2.7 Thread B，Turn 3：Proof Reconstruction Complexity . . . 5
2.8 Solver：单轮闭卷证明 . . . 5
2.9 Validity Reviewer：reference-blind 数学审查 . . . 5
2.10 Reference Evaluator：GT 辅助的 0–10 分评分 . . . 5
2.11 回退、停止与最终产出 . . . 6

参考实现 **6**

本文档汇报 PaperProof 当前拟采用的完整实验链路。系统以 2026 年 ML 理论论文为来源，将一篇论文的代表性理论贡献编译为一个匿名、闭卷、可评分的 paper-level proof task，再由独立 solver、validity reviewer 和 reference evaluator 完成证明与评分。

第一部分：基本信息与总体工作流

1.1 研究目标与实验单位

实验的基本单位是“论文级理论贡献”，而不是孤立抽取的每一个 theorem。每篇论文最多产生一个 flagship proof task；一个 task 可以整合一条定理链中的多个紧密相关结论，但公开题面优先只保留一个最终 claim，必要时至多两个不可分割的 claim。

完整链路包含五个核心线程：两个 formalization 线程、一个 solver 线程、一个 validity reviewer 线程和一个 reference evaluator 线程。正常完成一篇论文需要 9 个模型 turn；被早期筛除的论文只运行其中一部分。

核心线程	正常 turn 数	可见信息	主要输出
Thread A：论文与原文分析	3	完整论文来源、metadata、前序 turn 输出	triage、理论材料清单、flagship chains、原文 statement/proof au
Thread B：任务编译与复杂度评估	3	冻结的 flagship chain 及其经审查的材料闭包；不可见论文全文	public task、reference proof、rubric、provenance、PRC
Solver	1	仅 public task 和统一 solver prompt	闭卷证明答案
Validity Reviewer	1	public task 与移除自评分后的 solver proof	独立数学有效性报告
Reference Evaluator	1	task、solver proof、validity report、private GT 与 rubric	0–10 分、错误归属和可评分性结论

Thread A 的 triage 若返回 `filtered_out`，会额外触发一个独立的一轮 triage audit，以降低误筛风险。Thread B 若发现 proof-route exposure 或下游提出 task/rubric objection，会在原 Thread B 中增加 revision turn；若异议实际涉及原论文 statement 或 proof，则回到保留原文上下文的 Thread A 做 source re-audit。这些属于条件分支，不改变五个核心线程的职责划分。

1.2 预期输入数据

本轮计划重新处理上一轮已纳入的数据池。该数据覆盖 2026 年 1 月 1 日至 7 月 24 日的相应 arXiv 类别；新版不设置固定抽样篇数上限，也不再沿用“正式结果达到 6 个便只生成 DAG”的篇目限制。旧版的完整 formalization、DAG-only 和无正式结果标签只用于描述历史处理状态，不直接决定新版是否入选。

数据来源	上一轮纳入论文	旧版完整 formalization	旧版仅 DAG	旧版无正式结果	来源失败
primary category 为 `stat.ML`	1,587	684	587	312	4
ML 相关的 primary `math.OC`	289	148	90	51	0
primary `cs.LG` 且 cross-list `stat.ML`	1,452	607	425	417	3
合计	**3,328**	**1,439**	**1,102**	**780**	**7**

因此，登记输入池为 3,328 篇；其中 3,321 篇已有可运行来源，7 篇来源失败需要先恢复来源。新版会对全部可运行论文重新执行 contribution-level triage。最终 task 数量将低于输入论文数，因为 empirical/method-only 论文、理论闭包不足的论文、无法形成合格 flagship chain 的论文、存在阻断性原文问题的论文以及 PRC0 任务不会进入最终主 benchmark。

完整论文来源可以是 arXiv HTML、TeX、MinerU extract 或其他已经归档的可读正文；PDF 不是 agent 输入的硬性要求。论文身份与原文仅在数据构建端可见，闭卷 solver 不可见。

1.3 模型、运行方式与隔离

虚拟机批量实验默认使用 Get-Codex 中转、`gpt-5.6-sol` 和 `high` reasoning。Thread A、Thread B、validity reviewer 与 reference evaluator 使用隔离的 Codex agent 调用；solver 使用单次 Responses 请求的裸模型，不启用 agent 工具、网络或检索。

每个模型调用采用结构化输出 schema，并由代码做字段、依赖图、状态映射和暴露边界检查。模型不直接写仓库文件，runner 验证响应后再落盘。每次实验记录实际暴露文件、哈希、token usage 和最终状态。

1.4 时间与成本估计

现阶段只能给出校准区间，不能把不同版本的运行结果当成精确生产报价。

旧版 50 篇混合输入、稳定 10 并发
结果：约 50–70 分钟；官方等价成本约 55.66 美元，中转约 5.1–6.3 美元。
适用解释：更接近包含早期筛除样本的平均吞吐，但流程比当前版本简单。

当前 Stage 3 的 12 篇完成样本
结果：官方等价成本 48.41 美元，中转约 4.84 美元，即每篇完成任务约 4.03/0.40 美元。
适用解释：样本全部为能够完成且理论较强的论文，明显高估普通输入论文平均成本。

按旧版稳定吞吐直接外推，3,328 篇在 10 并发下的纯运行时间下界约为 56–78 小时。考虑当前版本增加的 source audit、任务审查、PRC、长尾论文和重试，暂以连续运行约 3–6 天作为工程预算。

按现有两组校准，3,328 篇的官方等价成本约在 3,700–13,400 美元之间；按中转约为官方十分之一估算，实际预算约为 370–1,340 美元。区间下端来自混合输入吞吐，上端是假设所有论文都像当前复杂完成样本一样走完整链路的保守上界。正式大规模运行前应使用最终提示词再跑一组约 50 篇的分层校准，以收窄时间和成本估计。

第二部分：各阶段职责与标准

2.1 数据准备与访问边界

Runner 从上一轮数据集中读取 metadata 和完整正文，并为每篇论文创建隔离运行。完整原文只服务于 Thread A；Thread B 只能看到通过 source audit 的选定材料闭包；solver 只能看到一个 public task；reviewer 不看 GT；evaluator 才能读取评分所需的 private GT、rubric 和 provenance。

这一隔离既防止 solver 通过论文身份或原文措辞检索答案，也防止前序选择被 solver 表现反向影响。所有输入暴露都写入 manifest，记录路径、哈希和字节数。

2.2 Thread A，Turn 1：Contribution Triage

Turn A1 阅读全文，先恢复论文自己声称的 broad principal contribution，再建立一个浅层理论框架清单。清单中的材料分为：`theory_candidate`、`internal_support`、`definition` 和 `external`，并记录直接可见的依赖关系。这里的目标是复现理论结构，不展开详细证明，也不判断定理正误。

论文被分为三类：

- `empirical_or_method_only`：理论仅为定义推论、常规计算或教材级说明，返回 `filtered_out / paper_not_theory_core`；
- `theory_auxiliary`：主要贡献仍是方法、算法或实验，但存在实质性辅助理论；只有该理论能够代表实际方法、具有完整 proof closure 且不是泛化的标准套用时才 `proceed`，否则返回 `filtered_out / paper_too_weak`；
- `theory_core`：非平凡、定理支撑的理论结果本身就是论文主要贡献，直接 `proceed`。

对于 `filtered_out`，独立 triage audit 会重新检查 principal contribution、理论清单和分类。它可以确认筛除，也可以纠正为 `proceed`；它不会提前做 target selection 或定理正确性审查。

对应规范见 Thread A Turn 1 与 Triage Audit。

2.3 Thread A，Turn 2：Flagship Target Selection

Turn A2 在不知道定理最终正误的前提下，从 `theory_candidate` 中构造 1–4 个 plausible flagship chains。一个 chain 表示一项连贯的 paper-level 科学结论，可以同时包含相互依赖、匹配上下界、必要与充分或等价方向等多个 candidate；definition、internal support 和 external result 只作为附带材料，不是公开结论。

多 candidate chain 必须执行 deletion test：如果删除某一 candidate 后仍能形成完整、自洽且代表论文主要理论贡献的结果，该 proper subchain 也必须单独进入比较，避免大而松散的 chain 自动胜出。

选择先看 Contribution Fidelity，再用 Difficulty Fidelity 打破同分：

- CF1 衡量对论文相关理论贡献的恢复范围；
- CF2 衡量科学结论与 theorem-chain closure 是否完整；
- CF3 衡量 scope economy，拼接可分离理论分支会受到严格惩罚；
- 任一 CF 维度为 0 的 chain 被淘汰，`CF_total >= 8` 的 chain 才进入后续排序；
- DF 只在 CF 相同或需要排序时比较 central bottleneck coverage、proof mechanism representativeness 和人为扩大 workload 的失真程度。

这一 turn 可以阅读原文证明以理解论文声称的 proof architecture，但不得测试反例、验证推导或因“看起来容易证明”而选题。这样把“贡献选择”与“正确性判断”分开，降低 selection bias。

对应规范见 Thread A Turn 2。

2.4 Thread A，Turn 3：Source Recovery And Audit

Turn A3 在 target ranking 已冻结后，回到原文恢复全部 theory candidates 和 internal supports 的完整 statement 与 source-grounded proof，并补齐任务相关 definitions 和 external dependencies。它对 statement 与 proof 分别给出状态：statement 为 `clean / minor_issue / major_issue`，proof 为 `clean / minor_error / major_gap`。

审查允许研究论文中常见且可从原文唯一恢复的轻微记号错误、局部 typo、简略步骤和常规推导；不会因为论文没有展开每一行计算就判定 major gap。只有具体、定理关键且无法由现有原文局部修复的问题才构成 major issue 或 major gap。若上游依赖存在 major 问题，代码会把影响传播到依赖它的下游 proof。

系统同时保留两个不同统计量：一是论文任意 substantive candidate 是否存在 major source issue；二是最终候选 chains 是否全部被其 candidate 或依赖闭包中的 major issue 阻断。前者用于论文质量的独立统计，不会自动停止任务；只有后者会停止 formalization。

代码按 CF、DF 和 chain 长度的既定顺序检查所有 `CF_total >= 8` 的 chains，选择首个未阻断的 chain。最高排名 chain 有问题时可以回退到下一条；只有全部合格 chains 都被阻断时才返回 `stopped / paper_issue_suspected`。

对应规范见 Thread A Turn 3，确定性合并与 gate 由 stage3_contracts.py 实现。

2.5 Thread B，Turn 1：Formalization Compile

Thread B 与 Thread A 隔离，不读取论文全文。Runner 只提供冻结 chain 及其经过审查的传递依赖闭包，因此 Thread B 负责“如何表达任务”，没有重新筛论文、改选 theorem 或重新解释原文的权限。

Turn B1 生成四类核心 artifact：

- `task.md`：匿名、自洽、闭卷的公开证明题；
- `proof_ground_truth.md`：在公开假设下闭合全部目标的私有参考证明；
- `rubric.md`：总分 10 分、包含 2–5 个数学核心步骤的私有评分标准；
- `provenance.json`：把公开 clauses 和私有 proof steps 映射回经审查的 source material IDs。

Flagship chain 是私有证明材料，不等于公开小题列表。公开 task 优先只保留一个 integrated final claim，必要时至多两个不可分割 claim；上游定理若主要服务于最终结论，应进入 private proof 与 rubric，而不是作为 `You may use`、allowed background、proof outline 或 ordered subquestion 暴露给 solver。

题面会删除论文标题、作者、arXiv ID、定理编号、独特方法名和可识别措辞。真正标准且独立于论文的数学背景由统一 solver policy 处理，不在每道题中针对性提示。

对应规范见 Thread B Turn 1。

2.6 Thread B，Turn 2：Formalization Artifact Audit

Turn B2 在同一 source-blind thread 中对刚生成的 artifact 做独立审查，检查：definition integrity、self-containment、source fidelity、anti-leakage、contribution fidelity、reference-proof validity、scope 和 rubric scorability。

若问题由 compiler 的转写、遗漏或任务组织造成，B2 直接返回修正后的完整字段；若经审查的材料本身不足，则请求 source re-audit，而不是自行猜测原文。它尤其检查两种相反失真：加入无关结果造成 scope inflation，以及删去匹配方向、关键瓶颈或必要结论造成 scope collapse。

对应规范见 Thread B Turn 2。

2.7 Thread B，Turn 3：Proof Reconstruction Complexity

PRC 是 solver 作答前对“从公开题面重构证明”的复杂度评估，不等于论文研究难度，也不使用模型实际得分定义难度。评估包含四个相互区分的 0–3 分维度：

- S：Strategy Discovery，发现核心证明路线的难度；
- D：Subgoal Structure and Dependency，组织实质子目标及其依赖的难度；
- T：Technical Reasoning and Execution，已知路线后完成关键数学推导的难度；
- C：Capability Integration，协调不同推理能力的难度。

四项之和为 intrinsic complexity。另行评估 proof-route exposure：E0 无明显泄漏；E1 有轻微路线提示并从总分扣 1；E2/E3 暴露了多项关键中间目标或决定性机制，必须退回 Thread B revision，不能直接给最终 PRC。

修订后有效总分映射为：0–3 为 PRC0/reject，4–6 为 PRC1/baseline，7–8 为 PRC2/primary，9–10 为 PRC3/primary，11–12 在同时满足 S=3、T=3 时才为 PRC4/stress，否则仍为 PRC3。

对应规范见 Thread B Turn 3。

2.8 Solver：单轮闭卷证明

Solver 是裸模型而不是可行动的 agent。每道题使用一个全新的单次请求，只暴露 public task、统一 system prompt 和统一 answer template；不开放网络、检索、文件系统或其他工具，也不暴露论文身份、原文、GT、rubric 或 provenance。

Solver 可以使用真正标准的数学或 ML 理论背景，但调用非初等 black-box theorem 时必须说明适用版本并核对任务中的假设。不确定是否属于标准背景时，应自行证明或明确记为 gap。若无法完成全部证明，应尽量完成正确的核心步骤，以便获得部分分。

答案包含 proof framework、full proof 和 self-assessment。Self-assessment 只用于记录模型自我认知，在进入 reviewer 和 evaluator 前由代码剥离，不参与评分。

对应规范见 solver prompt。

2.9 Validity Reviewer：reference-blind 数学审查

Validity reviewer 是独立的一轮 agent，只读取 public task 与已经移除 self-assessment 的 solver proof，不读取 rubric 或 reference proof，也不打分。它先抽取 theorem contract 和 proof dependency，再核查假设来源、关键推导、标准结论的适用条件、概率与收敛模式、边界情形，并对最薄弱的 1–3 个关键点做集中 adversarial checks。

Reviewer 不得在脑中补全 solver 未写出的证明后再判正确。输出状态为：`valid_complete`、`valid_with_minor_issue`、`incomplete_major_gap` 或 `target_suspected_invalid`。每个 finding 同时记录确定性与严重程度；只有具有精确数学理由的问题才能标为 verified break。

局部、无需新核心思想即可修复的问题可以是 minor；缺失核心桥梁、实质性额外假设或错误中间结论属于 major；若有具体理由怀疑公开 target 本身错误或缺少必要假设，则标记 `target_suspected_invalid` 并进入回退审查，而不是直接草率计零分。

对应规范见 validity reviewer prompt。

2.10 Reference Evaluator：GT 辅助的 0–10 分评分

Reference evaluator 在新的独立 agent thread 中读取 public task、solver proof、validity report、private reference proof、rubric 和 provenance。它先逐条处理 reviewer findings，再检查 task/GT/rubric 是否有问题，最后按核心步骤给 0–10 的整数分。

通用分档为：0 分表示没有正确相关思路；1–2 分表示有非平凡相关想法但没有完成有效核心步骤；3–7 分表示完成部分核心步骤但仍有 major gap；8–9 分表示所有目标均已完成，仅有局部可修复问题；10 分表示在精确假设下完全正确。完整且自洽的替代证明不要求复现 GT 路线，同样可以获得 8–10 分。

步骤分按依赖关系处理：若 solver 没有正确证明一个本身正确的中间结论，该步骤失去证明分，但后续从该结论进行的独立正确推导仍可得分；若中间结论本身错误或不可用，依赖它的后续步骤不能得分。仅提到方法名而未完成关键推导不能获得该步骤分。

Evaluator 还区分四类问题来源：solver proof、public task formalization、private GT/rubric 和 source theorem。唯一可确定的局部记号或提取 typo 可以修复后正常评分，不因 typo 本身扣 solver 分；缺失连续性、独立性、可测性等实质假设不能视为 typo。GT 的轻微错误或可局部补充的 core step 不必把整题标成 unscorable；只有 target 本身存在无法局部修复的重大错误时才进入人工复核。

对应规范见 reference evaluator prompt 与 evaluator 说明。

2.11 回退、停止与最终产出

正常链路以 `completed` 结束，并按 PRC 得到 `reject / baseline / primary / stress`。当前校准 runner 会让 PRC0/reject 任务也完成 solver 与 evaluator，以观察低复杂度任务的实际表现，但它们不进入最终主 benchmark。提前结束主要包括：triage 确认筛除、无合格 flagship chain、所有合格 chains 均被原文 major issue 阻断、来源材料不足且无法恢复，以及多轮受限修订后仍不自洽。

回退遵循职责边界：形式化转写或 rubric 问题回到原 Thread B revision；原文 statement/proof 异议回到保留全文上下文的 Thread A source re-audit；target selection 本身保持冻结，避免看到 solver 表现后改选更容易的定理。当前代码最多允许 2 次 proof-route exposure 修订、2 次 solver/reviewer validation feedback 和 1 次 source re-audit；修订后的任务需要重新通过 artifact audit、PRC、solver 和评测链路。

最终每篇完成论文保留 paper analysis、formalization artifacts、PRC、solver answer、validity report、evaluation、状态记录、usage 与 exposure manifest。聚合统计将分别报告 triage 结果、原文问题率、PRC 分布、solver 得分、reference 问题、token、成本和运行时间；不会把“论文任意理论结果存在问题”与“选中任务不可构建”混为同一指标。

参考实现

- 当前流程总览
- Stage 3 pipeline
- Stage 3 contracts
- 上一轮全量数据统计
- 旧版 50 篇端到端校准
- 当前 Stage 3 校准统计